




UNIVERSIDAD DE SEVILLA

Escuela Técnica Superior de Ingeniería Informática

Trabajo Dirigido de "Imágenes Biomédicas"
Curso 2022/2023

**Metodología de segmentación y procesamiento de imágenes para
la detección de tromboembolismo pulmonar**



Hebe Doello Ordóñez

Email de contacto:

hd.ordonez.2c@gmail.com

ÍNDICE

1. Resumen (Abstract).....	5
2. Introducción.....	6
3. Marco teórico del problema.....	7
3.1 Contexto biomédico.....	7
3.2 Contexto ingenieril.....	10
3.3 Imagen	13
4. Secciones.....	15
4.1 Bases de datos	15
4.2 Algoritmia.....	15
5. Experimentación.....	22
6. Resultados.....	25
7. Conclusiones	32
8. Bibliografía.....	34
Apéndice: Carga de trabajo de los componentes.....	38

LISTA DE FIGURAS

Ilustración 1: Tromboembolismo pulmonar	7
Ilustración 2: Tromboembolismo pulmonar	7
Ilustración 3: Diagrama de ubicaciones en los vasos arteriales pulmonares ...	8
Ilustración 4: CTPA de un paciente de 64 años diagnosticado con TEP	9
Ilustración 5: Gráfica de números de voxels y unidades de hounsfield	9
Ilustración 6: Planos reconstruidos a partir de la imagen CTPA	14
Ilustración 7: Corte coronal una vez realizado el proceso de padding para completar la imagen de 512 x 512 píxeles.....	17
Ilustración 8: Modelo de mezclas Gaussiano para corte axial	19
Ilustración 9: Modelo de mezclas Gaussiano para corte coronal	19
Ilustración 10: Modelo de mezclas Gaussiano para corte sagital.....	19
Ilustración 11: Cortes para la construcción de los volúmenes	20
Ilustración 12: Representación de volumen generado a partir de los cortes..	20
Ilustración 13: Operación de unión.....	21
Ilustración 14: Operación de intersección.....	21
Ilustración 15: Operación de mayoría.....	21
Ilustración 16: Volumen generado con su valor probabilístico	21
Ilustración 17: 3D Slicer construcción volumen ositrótico.....	22
Ilustración 18: Selección de 3 puntos semilla en 3D Slicer	23
Ilustración 19: Segmentación de los pulmones con 3D Slicer	23
Ilustración 20: Segmentación 3D y su respectiva representación a nivel espacial del paciente 3.....	25
Ilustración 21: Segmentación 3D y su respectiva representación a nivel espacial del paciente 13	25
Ilustración 22: Segmentación 3D y su respectiva representación a nivel espacial del paciente 29	26
Ilustración 23: Volúmenes resultado de la inferencia del paciente 3.....	27
Ilustración 24: Volúmenes unificados resultantes al aplicar las operaciones de: Unión, Intersección y Mayoría del paciente 3... ..	28
Ilustración 25: Puntos de intersección de los volúmenes unificados con el patrón de oro para el paciente 3.	28
Ilustración 26: Volúmenes resultado de la inferencia del paciente 13... ..	29
Ilustración 27: Volúmenes unificados resultantes al aplicar las operaciones de: Unión, Intersección y Mayoría del paciente 13... ..	29
Ilustración 28: Puntos de intersección de los volúmenes unificados con el patrón de oro para el paciente 13.... ..	29

Ilustración 29: Volúmenes resultado de la inferencia	30
Ilustración 30: Volúmenes unificados resultantes al aplicar las operaciones de: Unión, Intersección y Mayoría del paciente 29... ..	30
Ilustración 31: Puntos de intersección de los volúmenes unificados con el patrón de oro para el paciente 29.....	31

1. RESUMEN

El objetivo de nuestro trabajo consiste en la segmentación y procesamiento de diferentes imágenes biomédicas para la detección del tromboembolismo pulmonar (TEP), que es la oclusión o taponamiento de una parte del territorio arterial pulmonar a causa de un émbolo o trombo que procede de otra parte del cuerpo.

Palabras clave: tromboembolismo pulmonar (TEP), segmentación, pulmones, angiotomografía pulmonar computarizada (CTPA), MASK R-CNN, émbolo.

ABSTRACT

The goal of our work consists in the segmentation and processing of different biomedical images for the detection of pulmonary thromboembolism (TEP), which is the occlusion or plugging of a part of the pulmonary arterial territory due to an embolus or thrombus that comes from another part. of the body.

Keywords: pulmonary thromboembolism (TEP), segmentation, lungs, computed tomography pulmonary angiogram (CTPA), MASK R-CNN, plunger.



2. INTRODUCCIÓN

La TEP es una condición en la cual se presenta la obstrucción de una o más arterias pulmonares causada por la presencia de un trombo o coágulo sanguíneo que puede formarse en la misma cavidad arterial o migrar desde algún vaso sanguíneo, por lo general de los miembros inferiores, hacia los pulmones. Este trombo se termina depositando dentro de una sección de la arteria pulmonar lo cual genera un impacto en la actividad de ventilación y perfusión pulmonar que puede llevar a la hipoxemia, fallo cardíaco del ventrículo derecho y muerte súbita.

La angiotomografía pulmonar computarizada (CTPA) consiste en la obtención de imágenes de los vasos sanguíneos pulmonares resaltados por un medio de contraste. En una CTPA, los émbolos o trombos se identifican como defectos de llenado dentro de la arteria o vasos pulmonares que aparecen como regiones de alta intensidad debido al medio de contraste.

Un radiólogo promedio tiene una sensibilidad (término que hace referencia al porcentaje de diagnósticos correctos), que oscila entre el 77% y el 94%. Este porcentaje se puede ver afectado por la experiencia del especialista, su capacidad de atención, fatiga ocular y habilidad en la identificación de características especiales de los trombos o émbolos... Considerando lo anterior, la detección asistida por computador, por medio de algoritmos y programas especializados, podría facilitar la detección de émbolos y se considera una solución prometedora que apoyaría a los radiólogos, puesto que se estima que puede incrementar su sensibilidad hasta un 92–98%. No obstante, esta no ha sido adoptada completamente en la industria por la complejidad de algunos de los procesos necesarios para su funcionamiento, así como por los requerimientos computacionales y una tasa alta de detección de falsos positivos.

Por lo que el fin de este trabajo es mostrar las ventajas que puede traer consigo la unificación de múltiples modelos entrenados para cada plano, de manera que la información generada por cada uno construya un volumen único que pueda guiar a los expertos en el diagnóstico.

3. MARCO TEÓRICO DEL PROBLEMA

3.1 CONTEXTO BIOMÉDICO

Al haberme centrado en la detección de embolias pulmonares, será necesario hacer un breve recordatorio sobre la anatomía básica de los pulmones además de apuntar algunos aspectos importantes sobre las tromboembolias pulmonares.


La embolia pulmonar, también llamada enfermedad tromboembólica venosa, consiste en la formación de trombos en el sistema circulatorio venoso que pueden ser liberados en la circulación general y llegar a las arterias pulmonares. El trombo puede desarrollarse en un vaso sanguíneo en cualquier parte del cuerpo, a menudo en la pierna. La embolia pulmonar es una afección grave que puede causar un daño permanente en el pulmón afectado, bajos niveles de oxígeno en la sangre o lesiones en otros órganos del cuerpo por no recibir suficiente oxígeno.

La TEP es una condición cuya mortalidad y morbilidad puede ser reducida con un diagnóstico temprano. No obstante, sus síntomas no son específicos y el patrón de oro para diagnosticarla es la lectura del CTPA por parte de un radiólogo. Esta lectura trae consigo una serie de retos que buscan ser abordados por la detección asistida por computador.

Ilustración 1




Ilustración 2



Los casos de TEP tienen diversas categorías según su ubicación en las arterias, las cuales pueden ser periféricos, segmentarios, subsegmentarios, lobares y en "silla de montar" que es la que se refiere

a la bifurcación de la arteria principal. En la imagen se pueden identificar estas ubicaciones anatómicas.

Ilustración 3



Siendo el tipo I la arteria principal pulmonar, el tipo II la arteria pulmonar derecha e izquierda, el tipo III las arterias lobares, el tipo IV las arterias segmentarias y por último el tipo V las arterias subsegmentarias.


Angiotomografía pulmonar computarizada (CTPA)

La angiotomografía pulmonar computarizada es el método actual más confiable para el diagnóstico de la TEP, y consiste en la captura de imágenes de alta definición de los vasos arteriales pulmonares después de inyectar un medio de contraste vía intravenosa en el paciente. Este proceso requiere un cuidado especial por parte del especialista en el momento en el que se aplica el medio de contraste para obtener un resultado en el que se puedan distinguir los vasos arteriales con respecto a otros órganos y tejidos.

Durante el procedimiento, la zona torácica recibe una radiación ionizada que genera una imagen en escala de grises con diferentes intensidades para los diversos tejidos analizados. Estas intensidades, se miden según la escala de Hounsfield, la cual es una medida utilizada por los radiólogos en la interpretación de imágenes de tomografías computarizadas y que clasifica estas intensidades de acuerdo con la radiodensidad de diferentes materiales como el agua (0 UH), el aire (-1000 UH), y los huesos (700

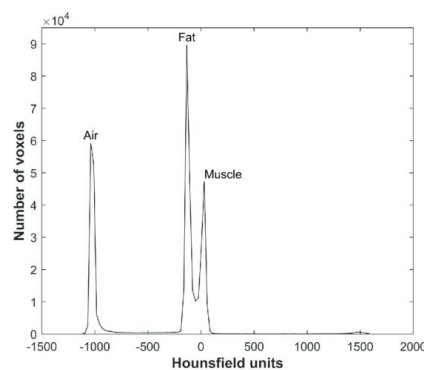
A 3000 UH).

Ilustración 4



Se puede generar un histograma donde en el eje X se puede representar las medidas Hounsfield y el eje Y el número de vóxeles que tienen esa medida. Aunque teóricamente la escala Hounsfield es una escala abierta, lo cierto es que en el ámbito del diagnóstico por imagen se ha establecido un rango de valores útiles que abarca desde -1024 HU hasta 3071 HU.

Ilustración 5



Teniendo en cuenta los diferentes modelos y las principales dificultades identificadas para los radiólogos, se concluye que el tamaño de un émbolo y su localización influye en la dificultad para su detección. Por esta razón, el modelo P-Mask RCNN es un buen punto de partida, ya que además de enfocarse en objetos pequeños genera como resultado una clasificación y su segmentación, por lo que estos resultados permiten con mayor facilidad señalar una zona en la que los radiólogos se podrían enfocar para adelantar el diagnóstico de TEP.

3.2 CONTEXTO INGENIERIL

La idea principal de mi proyecto se basa en el procesamiento de la imagen y en una posterior segmentación. Por ello, debemos entender qué significan estos conceptos.

Procesamiento de la imagen digital

El procesamiento de imágenes digitales está definido como el conjunto de técnicas que se aplican a estas con el fin de aumentar la calidad o facilitar la búsqueda de información. Mejoran el aspecto y hacen más evidentes ciertos detalles que se desean resaltar en la imagen. Como sabemos, las imágenes digitales están divididas en píxeles o en vóxeles con diferentes valores de intensidad. La función del procesamiento es alterar los valores de luminosidad mediante operaciones matemáticas y representar esta imagen resultante. Dentro de las técnicas de procesamiento encontramos técnicas de digitalización, representación, compresión, preprocesamiento, filtros, morfología matemática, segmentación, reconocimiento, visualización, etc.

Preprocesamiento y filtrado

Las técnicas de preprocesamiento y filtrado son técnicas de procesamiento, las cuales se utilizan principalmente para aumentar la calidad de la imagen. Son muy útiles ya que en muchas ocasiones y por razones diversas, la calidad de la imagen es deficiente y contiene ruido. El ruido es una variación aleatoria del brillo o color de la imagen y hace que esta no se corresponda con la realidad. Por ejemplo, dificulta procesos de tratamiento de la imagen. Existen gran cantidad de tipos de ruido y a su vez, muchos tipos de filtros con el fin de eliminarlos de la mejor manera posible. Algunos ejemplos de ruido son los siguientes: ruido gaussiano (asociado a la radiación electromagnética), ruido de pimienta y sal (producido normalmente por el empleo de aparatos electrónicos antiguos) y ruido de crominancia (asociado con exposiciones prolongadas en las que el sensor se calienta). Por el contrario, algunos ejemplos de filtros para la eliminación de ruido son: filtro gaussiano, filtro de mediana, filtro

de la media ponderada... Hay filtros que son capaces de eliminar el ruido, sin embargo suelen producir como consecuencia un empeoramiento de la calidad de la imagen. Por lo tanto, es usual aplicar posteriormente otro filtro distinto para paliar este efecto.

Las técnicas de filtrado sobre imágenes digitales se pueden clasificar en dos grandes grupos: técnicas en el dominio espacial y técnicas en el dominio de la frecuencia. Mientras que las primeras tienen su efecto sobre la aglomeración de píxeles que componen la imagen y sus vecinos, las técnicas en el dominio de la frecuencia hacen modificaciones sobre la transformada de Fourier de la imagen.

Segmentación

La segmentación es la partición de una imagen en regiones o grupos de píxeles que satisfacen unas condiciones particulares permitiendo destacar zonas con características específicas de forma o color. Su principal objetivo es aislar regiones de interés y son especialmente útiles para visualizar zonas concretas tanto de una imagen bidimensional como de una tridimensional.

Forma parte de las técnicas de procesamiento de imágenes y sus atributos principales son amplitud de luminosidad, colores, bordes y texturas. Además, la segmentación puede clasificarse en:

- Segmentación contextual: valora las características del propio píxel y sus vecinos y encontramos: discontinuidad y similaridad. La discontinuidad divide la imagen digital centrándose principalmente en los cambios bruscos de nivel de gris. Entre ellos podemos encontrar la detección de puntos aislados, detección de líneas y la detección de bordes. Por otro lado, la similaridad presenta regularidad en los valores del nivel de gris (agrupa los píxeles con características similares) y los métodos principales son la umbralización, crecimiento de región y división y fusión de regiones.
- Segmentación no contextual no tiene en cuenta las relaciones entre objetos de la imagen, de manera que los píxeles se agruparán según un atributo común como el color, intensidad, etc.

En el caso de la TEP, se busca identificar los píxeles en la imagen que corresponden a una tromboembolia, y en el caso donde existan diferentes apariciones de TEP que sean etiquetadas de manera independiente. Por esta razón, el modelo está basado en uno de los modelos más populares para segmentación de instancias en los últimos años: Mask R-CNN.

Mask R-CNN

Es un algoritmo de segmentación de instancias que deriva de una familia de algoritmos basados en generar propuestas regionales para la clasificación y detección de objetos dentro de una imagen. Algunos de estos algoritmos son:

- Region Proposal Network (RPN): es una red convolucional que predice simultáneamente los límites de los objetos y las puntuaciones de objetualidad en cada posición. Los RPN están diseñados para predecir de manera eficiente las regiones con una amplia gama de escalas y relaciones de aspecto. Es decir, se encarga de generar regiones de interés rectangulares a partir del mapa de activación de una imagen. Esta red utiliza unas cajas de anclaje rectangulares de diferente escala sobre secciones de la imagen en la que se va desplazando la red y genera unas puntuaciones de presencia o no presencia de un objeto.
- Generación de máscara: se genera una máscara binaria para el objeto localizado.

Por lo tanto, los pasos que obtendríamos al aplicar el algoritmo MASK R-CCN serán los siguientes:

- Primero, a partir de una imagen de entrada, se genera un mapa de activación por medio de una red neuronal convolucional.
- Después, por medio de la RPN, se generan unas regiones de interés sobre este mapa de activación.
- A continuación, se extraen los mapas de activación de las regiones de interés y se alinean de acuerdo con el tamaño de la entrada para que haya una correspondencia píxel a píxel.

- De forma paralela se genera la clasificación, la localización con la caja delimitadora y una máscara binaria.

Como hemos dicho anteriormente Mask R-CNN es un algoritmo que se basa en la selección de regiones de interés a partir de la probabilidad de localización de la TEP teniendo en cuenta la localización de sus ocurrencias en el conjunto de datos. Y por lo tanto debemos saber que essta selección de las regiones se realiza por medio de un modelo de probabilidad llamado modelo de mezcla Gaussiana o Gaussian Mixture Model (GMM).

Este algoritmo trata de buscar datos en nuestro conjunto de datos que comparten características comunes y los agrupa. Por lo tanto, con este modelo y contemplando el conocimiento previo de la ubicación de las TEP, en el conjunto de datos se realiza un muestreo para seleccionar una región de interés y extraer las cajas de anclaje sobre las mismas.


3.3 IMAGEN

Para la obtención de la imagen de CTPA, hemos investigado en gran cantidad de bases de datos de imágenes médicas como OPENi, Grand-Challenge, JSRT, MR Lession, Kaggle, TCIA Browser: Cancer Imaging Archive, y Science Source Images entre otras. Finalmente, he decidido obtener la imagen de la base de datos de FUMPE.

Las imágenes obtenidas como resultado de CTPA se almacenan en un archivo de formato especial, por lo general formato DICOM, y se organizan en diferentes cortes con un espesor y espaciado específico, conformando un volumen del área torácica para un determinado paciente.

El formato DICOM es un estándar para la transmisión e integración de imágenes médicas y datos entre diferentes dispositivos, y es bastante utilizado para el almacenamiento de imágenes resultado de un CTPA. Una imagen de CTPA en 3D se almacena como una serie de archivos que representan diferentes cortes que contienen unos encabezados con metadatos correspondientes al paciente y a la serie de imágenes.

Ilustración 6



4. SECCIONES

4.1 BASES DE DATOS

Para la obtención de la imagen de resonancia magnética, hemos investigado en gran cantidad de bases de datos de imágenes médicas como pueden ser OPENi, Grand-Challenge, JSRT, MR Lession, Kaggle, TCIA Browser: Cancer Imaging Archive, NCBI, MIDAS, OASIS y Science Source Images entre otras. Finalmente, he decidido obtener la imagen de la base de datos de FUMPE.

El conjunto de datos FUMPE cuenta con imágenes volumétricas resultado de una tomografía 28 computarizada de 35 pacientes en formato DICOM para un total de 8792 cortes axiales. De los 35 pacientes analizados, 2 pacientes no presentan ocurrencia de TEP y, por lo tanto, son 33 las imágenes que cuentan con cortes anotados. Ya que tenemos diferentes imágenes con cortes axiales, sagitales y coronales respectivamente, se evidencia la necesidad de hacer un preprocesamiento de las imágenes CTPA para reconstruir los cortes adicionales.

4.2 ALGORITMIA

El proceso por el que se somete la imagen para la detección de embolias pulmonares cuenta con cuatro pasos principalmente. Primero nos encargaremos de preprocesamiento de la imagen CTPA para la generación de los cortes en los planos axial, coronal y sagital. Después la detección realizada a través del modelo Mask R-CNN para cada plano. Una vez hecho esto debemos reconstruir los volúmenes con los resultados de la detección y por último debemos generar un modelo unificado.

Paso 1: Preprocesamiento

Utilizando la librería "Simpleitk" del lenguaje de programación Python, es posible reconstruir las imágenes volumétricas como matrices. Sin embargo, al obtener los cortes sagitales y coronales para cada paciente y convertirlos en archivos con formato .JPG se obtienen imágenes deformadas o estiradas. Además, en los encabezados del formato DICOM,

es posible ver el espaciado entre píxeles en el campo Pixel Spacing que es la distancia en milímetros entre los centros de cada píxel en el eje X y Y. En nuestro conjunto de imágenes estos valores son iguales generando un cuadrado, por lo que se toman como los valores X y Y del vóxel. Para el valor del eje Z del vóxel se utiliza el campo Slice Thickness de DICOM que retorna el grosor del corte.

Una vez obtenidos estos valores podemos darnos cuenta de que el vóxel es anisotrópico (sus dimensiones no son iguales) y para una reconstrucción de los cortes coronales y sagitales, es necesario transformarlos en vóxeles isotrópicos (todos sus lados del mismo tamaño), a través de la interpolación del volumen.

Para ello seguimos los siguientes pasos:

- 1- Se carga la imagen volumétrica de un paciente a partir de la serie de imágenes DICOM
- 2- Se asigna el valor del espesor de los cortes con el mismo valor que tienen las dimensiones X y Y, obteniendo de esta manera una imagen con vóxeles isotrópicos
- 3- Se calculan las nuevas dimensiones que tendrá la imagen en píxeles. (aumenta o disminuye el número de cortes axiales, pero los coronales y sagitales se mantienen iguales).
- 4- La intensidad la ponemos a un valor entre 0 y 255.
- 5- La imagen resultante se convierte en una matriz.
- 6- Se extraen los cortes para cada uno de los planos desde la matriz generada y se almacenan como archivos JPG.

Otra opción cuando tenemos una imagen que no tiene todos los lados con las mismas dimensiones es realizar un proceso denominado "*padding*" en el que se rellenan los píxeles faltantes con valor 0 hasta alcanzar las dimensiones requeridas. Dado que en todos los cortes el ancho de la imagen se mantiene en 512 píxeles, se genera un script encargado de llenar con ceros la parte inferior de todos los cortes hasta completar una

imagen cuadrada de 512 x 512 píxeles. Podemos ver como se ha rellenado con ceros la parte superior de esta imagen:

Ilustración 7



Paso 2: Entrenamiento

El entrenamiento de la red se lleva a cabo mediante un proceso de aprendizaje por transferencia o transfer learning, donde los pesos iniciales de la red neuronal son los pesos generados como resultado del entrenamiento de otra red con datos similares a los del problema. En este caso, se utilizó la versión más reciente de los pesos preentrenados del modelo Mask-RCN, los cuales se encuentran disponibles para descarga en el repositorio de GitHub de Mask R-CNN.

Gaussian Mixed Model (GMM)

El modelo de mezcla gaussiano (MMG) asigna cada observación a un cluster maximizando la probabilidad a posteriori de que un punto de datos pertenezca al cluster asignado. El planteamiento del modelo de mezclas gaussianas es el siguiente:

Sea $Y = [Y_1, Y_2, \dots, Y_D]^T$ una variable aleatoria real D-dimensional. Se dice que la distribución de Y sigue una distribución mezcla finita si su función densidad de probabilidad (fdp) se puede escribir como una combinación lineal de fdp's elementales

$$p(y/\theta) = \sum_{i=1}^I \alpha_i p(y/C = i, \beta_i), \quad i \in \{1, \dots, I\}$$

Donde I representa el número de distribuciones elementales (componentes) de la mezcla, $C = 1, 2, \dots, I$, y θ representa el conjunto de parámetros

$$\theta = \{\alpha_1, \dots, \alpha_I, \beta_1, \dots, \beta_I\}$$

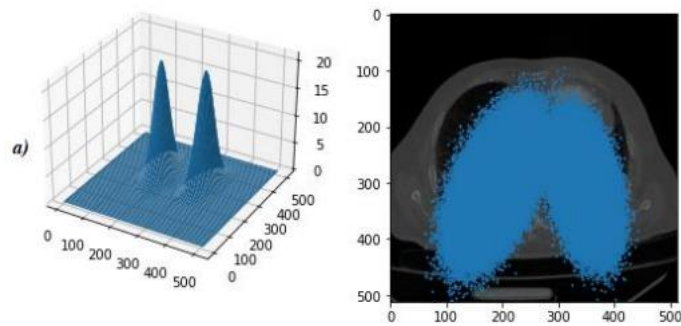


Siendo $\beta = \{\beta_1, \dots, \beta_I\}$ el conjunto de parámetros asociados a cada distribución de la mezcla y $\alpha = \{\alpha_1, \dots, \alpha_I\}$ la probabilidad o peso de cada distribución de la mezcla. Cuando las distribuciones que componen la mezcla son Gaussianas, la función densidad de probabilidad se conoce como mezcla gaussiana. Por tanto, una mezcla Gaussiana es una distribución probabilística cuya fdp es una combinación lineal de distribuciones Gaussianas

$$p(y/\theta) = \sum_{i=1}^I \alpha_i N(y/C = i, \beta_i)$$

Siendo

$$N(y/C = i, \beta_i) = \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left(-\frac{1}{2} (y - \mu_i)^T \Sigma_i^{-1} (y - \mu_i)\right)$$

La construcción del modelo de mezclas Gaussiano se realiza tomando todos los centros de las cajas delimitadoras, resultado de la conversión de las anotaciones del conjunto de datos de entrenamiento (proceso realizado por el experto), al formato COCO. Con estos puntos, se genera el modelo de probabilidad GMM y a partir de este, se realiza el muestreo de un número de puntos que se utilizarán para definir las regiones candidatas para la extracción de las cajas de anclaje. Estos puntos de muestreo se almacenan en un archivo de texto que hace parte de los parámetros de entrada del entrenamiento y la inferencia del modelo

Ilustración 8**Ilustración 9****Ilustración 10**

En estas 3 ilustraciones podemos ver el resultado del modelo de mezclas Gaussianas (GMM) y de los puntos de muestreo obtenidos para los conjuntos de datos de cortes en los planos axial, coronal y sagital.

Paso 3: Inferencia

Una vez entrenados los modelos para cada plano, se puede ejecutar el proceso de inferencia donde la entrada es una imagen volumétrica de un paciente. Esta imagen pasa por la etapa de preprocesamiento donde se divide en cortes para el plano axial, sagital y coronal. Cada grupo de 35

cortes sirve de entrada para cada modelo entrenado y su salida, es la predicción de la segmentación para cada corte de entrada. Con este grupo de imágenes de predicción por corte se reconstruye el volumen en nuevamente, quedando como resultado de la inferencia tres volúmenes construidos con los resultados de cada uno de los modelos.

Aquí podemos ver un ejemplo de una representación del volumen generado a partir de los cortes resultado de la inferencia:

Ilustración 11






Ilustración 12




Paso 4: Generación de volumen unificado

Para la generación de volumen final, los tres volúmenes que tienen las mismas dimensiones pasan por una etapa donde se realiza una operación de conjuntos sobre el volumen completo. Las operaciones para la generación del volumen final en este ejercicio son:

- Unión: se mantienen todas las detecciones de TEP realizadas por los tres volúmenes con la 36 operación lógica OR.

Ilustración 13


- **Intersección:** sólo se mantienen los vóxeles donde los tres volúmenes hacen una detección positiva de presencia de TEP con la operación lógica AND.

Ilustración 14

- **Mayoría:** se mantienen los vóxeles donde al menos dos de los tres volúmenes hacen una detección positiva de presencia de TEP.

Ilustración 15

Estas operaciones permiten enriquecer un volumen resultado de acuerdo con la información de los diferentes planos, o también enfocar la atención en aquellos lugares donde exista una coincidencia en cuanto a la detección.

Ilustración 16

Esta imagen es un ejemplo de un volumen generado con su valor probabilístico. En este volumen se representan las probabilidades de la

clasificación de un TEP en cada uno de los cortes.

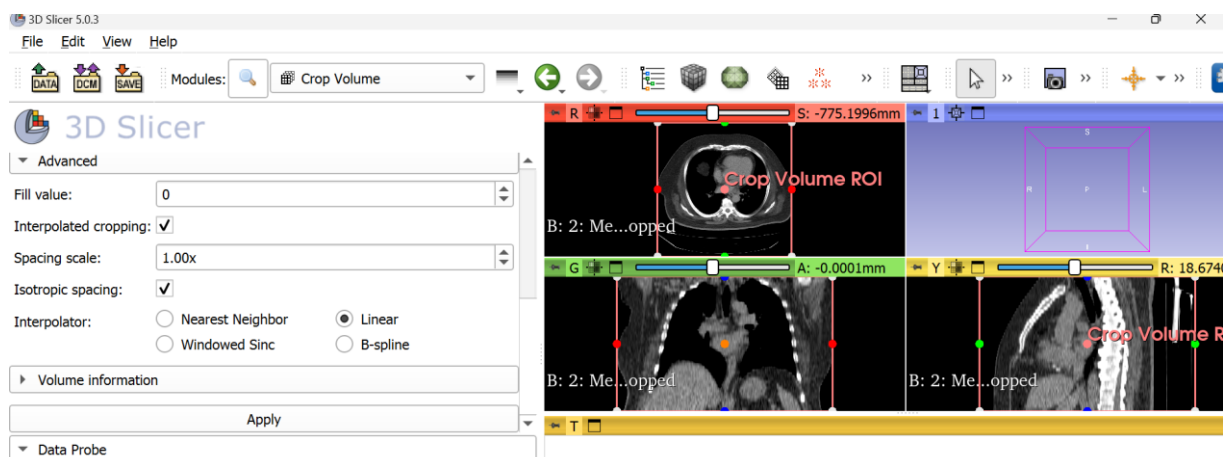
5. EXPERIMENTACIÓN

Antes que nada, debemos tomar nuestras imágenes obtenidas a través de Tac e introducirlas en 3D Slicer para poder visualizarlas. Para ello, seleccionamos el módulo "DICOM", después, "show DICOM database" y una vez aquí escogemos las imágenes a visualizar y pulsamos "Load". Se mostrarán las tres vistas en el visor, una para corte (axial, sagital y coronal).

Una vez hayamos cargado la base de datos, previamente a la segmentación necesitaremos llevar a cabo diferentes procesos. En primer lugar, comprobaremos la resolución de las imágenes para asegurarnos que poseemos vóxeles isotrópicos, es decir, que el tamaño del vóxel sea el mismo a lo largo de cada uno de los ejes. Una vez comprobado esto, en el módulo "Crop Volume" procederemos a quitar las regiones que no sean relevantes. Para ello hacemos cultivos interpolados, forzando el espaciado isotrópico.

Pinchamos en la lupa que se encuentra justo a la derecha de "Modules:" en la esquina izquierda de arriba. Buscamos el módulo "Crop Volume". Una vez dentro del módulo, pinchamos en "Fix" y seleccionamos la opción "Isotropic Spacing". De esta forma conseguiremos que los espaciados isotrópicos se igualen en valor en todos los ejes.

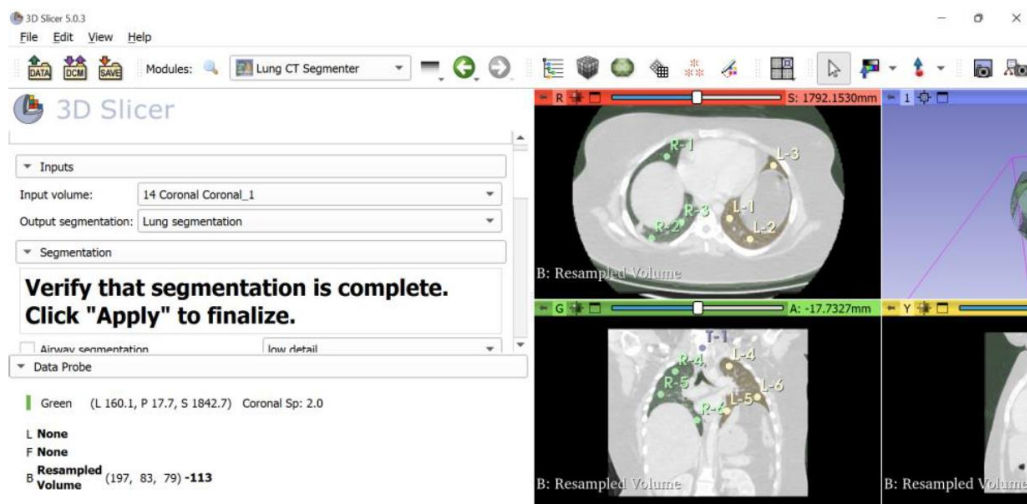
Ilustración 17



Una vez hecho esto, pinchamos en la lupa que se encuentra justo a la

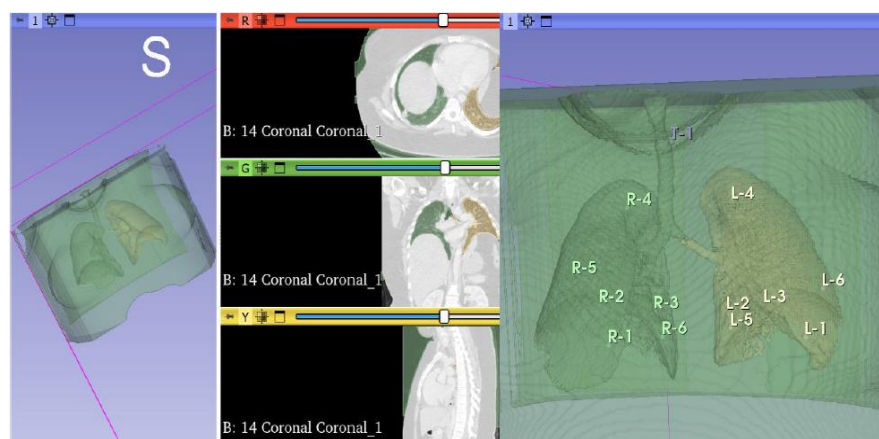
derecha de "Modules:" en la esquina izquierda de arriba y buscamos el módulo "Lung CT Segmenter", previamente instalado. En este módulo debemos seleccionar tres puntos semilla en cada pulmón en la imagen tomada desde el plano axial, además, debemos marcar tres puntos semilla más en cada pulmón y uno en la tráquea en la imagen tomada desde el eje coronal.

Ilustración 18



Una vez hemos terminado de marcar los puntos semilla, se nos muestra la previsualización de los pulmones.

Ilustración 19



Repetimos este proceso para cada uno de los pacientes que vayamos a tratar de diagnosticar. Y una vez tenemos la segmentación de las imágenes como hemos indicado anteriormente, debemos mediante un código Python encontrar y detectar la incidencia de embolia pulmonar en

ellas.

Para ello, como hemos comentado, trabajaremos con imágenes bidimensionales del corte de una angiogramografía computarizada en la que podemos observar diferentes tipos de tromboembolias pulmonares. En primer lugar, abrimos Python en el ordenador e instalamos las librerías de que utilizaremos posteriormente para realizar operaciones. Ejecutamos los siguientes comandos:

- `pip install -r requirements.txt`
- `python sampling/sample.py`

"Sampling.sample.py" es el módulo de python para crear GMM (modelo de mezcla) y puntos de muestra a partir de GMM, y una vez creados lo guardamos en el directorio de ubicaciones. Es decir, ejecutando el correspondiente código podemos trazar el GMM en un sistema de coordenadas 3D

Además, si no se tienen ya instaladas las librerías Numpy, Opencv-python y Matplotlib, se deben también instalar antes de empezar a ejecutar los comandos. Comenzando con la programación en el entorno de Jupyter, importamos en primer lugar, las distintas librerías instaladas previamente y paquetes con los que vamos a trabajar durante todo el proceso para tenerlas ya disponibles y no tener que realizar importaciones adicionales más adelante.

Una vez cargados nuestras librerías debemos entrenar nuestra red a través del siguiente código:

- `python pulmonary_embolism.py training --dataset="your dataset path" --model="your model weight file.h5"`

Además, para evaluar el entrenamiento de nuestra red, introducimos el siguiente trozo de código:

- `python pulmonary_embolism.py inference --dataset="your dataset path" --model="your model weight file.h5"`

"Pulmonary_embolism.py" es el archivo principal para entrenar y validar nuestro algoritmo P_Mask_RCNN.

Este código puede descargar pesos de COCO preentrenados (mask_rcnn_coco.h5) desde la página de lanzamientos para iniciar el peso del modelo. Aunque en este trabajo yo he usado un modelo que está ya preentrenado evaluar P_Mask_RCNN directamente, por lo que este paso no ha sido necesario.

He usado un modelo ya entrenado de P_Mask_RCNN, ya que entrenarlo una red es un paso de programación avanzada y que requiere mucho conocimiento del tema, y a pesar de intentarlo no he podido.

Por lo tanto, únicamente debemos introducir nuestras imágenes previamente segmentadas en 3D y a partir de ellas contrastaremos los resultados de los diferentes pacientes.

6. RESULTADOS

Se utilizan las imágenes CTPA de tres pacientes que habían sido separadas anteriormente: pacientes 3, 13 y 29, cuyos volúmenes generados ase observan en la imagen, se han calculado en el apartado anterior de segmentación de imágenes:

Ilustración 20




Ilustración 21





Ilustración 22

Estas imágenes, ya segmentadas, pasaron a través del proceso de reconstrucción de los cortes axiales, sagitales y coronales, y se utilizaron para reconstruir un volumen y así se obtuvieron tres volúmenes diferentes con la inferencia de cada modelo desde cada plano. Finalmente, estos volúmenes pasaron por la fase de unificación donde se probaron tres métodos para generar un resultado final: unión, intersección y mayoría.

Tomamos el volumen generado con las anotaciones de los expertos o patrón de oro y los demás volúmenes generados y construimos una tabla, para realizar una operación de intersección y así identificar en cuántos puntos coincidían los volúmenes resultantes de esta metodología con el patrón de oro. A continuación, se muestra el resultado de este proceso para cada operación en cada paciente.

<i>Puntos con ocurrencia de TEP en los volúmenes</i>			
	<i>Paciente 3</i>	<i>Paciente 13</i>	<i>Paciente 29</i>
<i>Punto de oro</i>	47382	33571	65987
<i>Axial</i>	41520	23171	52694
<i>Sagital</i>	62815	22856	66426
<i>Coronal</i>	51282	25577	50908

A continuación, se muestra la tabla con la cantidad de puntos de detección positiva de TEP para un volumen de acuerdo con el patrón de oro.


<i>Detecciones Positivas</i>			
	<i>Paciente 3</i>	<i>Paciente 13</i>	<i>Paciente 29</i>
<i>Axial</i>	19589	10055	38455
<i>Sagital</i>	1092	690	9759
<i>Coronal</i>	1743	695	5740
<i>Unión</i>	21692	10756	44151
<i>Intersección</i>	53	159	874
<i>Mayoría</i>	679	525	8929

Ahora analizaremos uno a uno cada uno de los tres pacientes de los cuales hemos obtenido los datos.

- Paciente 3:

Para el Paciente 3, en la primera tabla realizada se muestra que tenemos una cantidad de puntos identificados como TEP más alta que en el patrón de oro en los cortes sagital y coronal, esto quiere decir que hay un número elevado de falsos positivos (FP) para ambos cortes. En la siguiente ilustración vemos los volúmenes resultados de la inferencia tomando los cortes axiales, sagitales y coroneles para el Paciente 3

Ilustración 23



Además, podemos ver que el modelo axial resultante del paciente 3 tuvo una cantidad de detecciones positivas mucho mayor que los otros dos cortes con 19589 puntos frente a 1092 del modelo sagital y 1743 del coronal (como hemos visto en la segunda tabla realizada con los datos obtenidos).

Finalmente, construimos 6 gráficas. Las tres primeras correspondientes a

los volúmenes resultantes al aplicar las operaciones de unión, intersección y mayoría entre los volúmenes resultado de la inferencia de los cortes axiales, sagitales y coronales para el paciente 3. Y las tres restantes serán las gráficas correspondientes a los puntos de intersección de los volúmenes con el patrón de oro.

Ilustración 24





Ilustración 25




Basándonos en los resultados de las dos graficas anteriores podemos concluir que aunque el volumen de la unión, genera más ruido por incluir falsos positivos, llega a detectar un poco menos de la mitad de los puntos existentes con 21692 puntos. La intersección es mucho más localizada y sólo logra una detección positiva de 53 puntos, mientras que la mayoría alcanza los 679.

- Paciente 13:

Representando los datos mediante una gráfica de volúmenes resultado de la inferencia tomando los cortes axiales, sagitales y coronales, podemos observar cómo para el paciente 13, se presenta un equilibrio más grande respecto al número de puntos de TEP detectados entre los diferentes

modelos y el número de puntos del patrón de oro.

Ilustración 26



Finalmente, construimos de nuevo las 6 gráficas. Las tres primeras correspondientes a los volúmenes resultantes al aplicar las operaciones de unión, intersección y mayoría entre los volúmenes resultado de la inferencia de los cortes axiales, sagitales y coronales para el paciente 3. Y las tres restantes serán las gráficas correspondientes a los puntos de intersección de los volúmenes con el patrón de oro.

Ilustración 27





Ilustración 28




Observamos un modelo de unión con bastante ruido y una intersección

muy localizada.

- Paciente 29:

Generamos al igual que para los otros dos pacientes las gráficas con los volúmenes resultado de la inferencia de los cortes, a partir de los datos obtenidos anteriormente. Siendo los puntos para cada corte 52694 puntos del axial, 66426 puntos del coronal y 50908 puntos del modelo sagital.

Ilustración 29



Finalmente, construimos de nuevo las 6 gráficas. Las tres primeras correspondientes a los volúmenes resultantes al aplicar las operaciones de unión, intersección y mayoría entre los volúmenes resultado de la inferencia de los cortes axiales, sagitales y coroneales para el paciente 3. Y las tres restantes serán las gráficas correspondientes a los puntos de intersección de los volúmenes con el patrón de oro.

Ilustración 30





Ilustración 31

Como podemos observar, se repite el escenario de los otros dos pacientes para los volúmenes unificados y su coincidencia con el patrón de oro. La unión logra coincidir en casi un 70% con 44151 puntos, y la intersección y la mayoría mantienen su tasa de aciertos considerando que tienen un menor número de puntos.

A partir de estos resultados y comparando las gráficas de los tres pacientes concluimos que la operación de la unión logra un porcentaje de detecciones positivas promedio del 48% (o mayor ya que en el del paciente 29 tenemos un 66%). Siendo el modelo axial el que mas aporta en esta operación.

Además, considerando estas operaciones para el volumen unificado, se puede afirmar que el caso de la intersección funciona como un volumen que se concentra en zonas específicas donde los tres modelos generan una detección de TEP. Y por último el de mayoría también puede ser utilizado como un volumen para verificar la concentración de detecciones.

Para ver los resultados de una manera mas visual, construimos una última tabla con los porcentajes de deyecciones positivas por cada volumen generado.

<i>Porcentaje de detecciones positivas</i>				
	<i>Paciente 3</i>	<i>Paciente 13</i>	<i>Paciente 29</i>	<i>Promedio</i>
<i>Volúmenes de cada plano</i>				
<i>Axial</i>	0,41342704	0,299514462	0,582766302	0,431902601
<i>Sagital</i>	0,023046727	0,020553454	0,147892767	0,063830983
<i>Coronal</i>	0,036786121	0,020702392	0,086986831	0,048158448
<i>Volúmenes unificados</i>				
<i>Unión</i>	0,457810983	0,32039558	0,669086335	0,482430966
<i>Intersección</i>	0,001118568	0,004736231	0,013245033	0,006366611
<i>Mayoría</i>	0,014330336	0,015638498	0,135314532	0,055094455

En resumen, una vez analizados los resultados para estos tres pacientes ejemplo, llegamos a las siguientes conclusiones:

1. Frente a los volúmenes entrenados, el modelo axial supera con creces los modelos de los otros cortes (sagital y coronal)
2. En cuanto a los volúmenes unificados, la operación de la unión alcanza el mejor porcentaje de detecciones al agrupar los resultados de todos los modelos, pero genera ruido al almacenar falsos positivos.
3. Las operaciones de intersección y mayoría, tienen un menor porcentaje de detecciones debido a que tienden a descartar parte de la información, pero pueden ser de gran utilidad para el análisis de áreas donde se tenga confirmación de detección en más de un plano.

7. CONCLUSIONES

A partir de los resultados obtenidos, a continuación, se presentan las conclusiones de las pruebas realizadas y de la fiabilidad de la utilización del proceso para la detección de tromboembolias pulmonares en imágenes obtenidas por angiotomografía computarizada.

- Frente a los volúmenes entrenados, el modelo axial supera con creces los modelos de los otros cortes (sagital y coronal). Esto

puede deberse a que las anotaciones de los expertos del conjunto de datos fueron realizadas principalmente sobre el plano axial y al reconstruir los otros dos planos se puede llegar a perder un poco la calidad de la anotación, o también puede deberse a que cada modelo requiera un ajuste específico de sus parámetros para cada caso.

Por lo tanto llegamos a la conclusión de que no es suficiente tener un único modelo con una configuración que sirva para los diferentes planos, y es necesario invertir el tiempo en su personalización para buscar los parámetros y configuración necesaria que se ajuste a cada uno de ellos.

- Los resultados de la metodología implementada en este trabajo de investigación indica que existe un aporte positivo de los tres modelos entrenados, pese a los bajos resultados obtenidos por dos de ellos (sagital y coronal), durante el proceso de entrenamiento.

En el caso de la operación de la unión, se confirma un aumento en el porcentaje de detecciones positivas respecto a cada modelo individual. Sin embargo, para las operaciones de intersección y mayoría, aunque no hay evidencia de un aumento en el porcentaje de detecciones debido a la naturaleza de dichas operaciones, sí se enriquece el resultado al generar unos volúmenes que contienen la confirmación de detección por más de un modelo. De esta manera, se puede afirmar que esta solución puede facilitar y apoyar la labor diagnóstica de los radiólogos y especialistas en la detección y búsqueda de TEP.

Este resultado, con plena seguridad se podrá mejorar y se obtendrá una segmentación mucho mejor si se abordan algunas de las limitaciones que se identificaron durante esta investigación, como por ejemplo:

8. BIBLIOGRAFÍA

- [1] Gorordo-Delsol, L. A., Zamora-Gómez, S. E., David Hernández-López, G., Teresa, M., García-Román, A., Jiménez-Ruiz, A., Tercero-Guevara, B. I., & Crítica, M. (s/f). *Tromboembolia pulmonar: revisión sistemática y algoritmo diagnóstico-terapéutico*. Medigraphic.com. Recuperado de: <https://www.medigraphic.com/pdfs/juarez/ju-2015/ju152f.pdf>
- [2] Masoudi, M., Pourreza, H.-R., Saadatmand-Tarzjan, M., Eftekhari, N., Zargar, F. S., & Rad, M. P. (2018). A new dataset of computed-tomography angiography images for computer-aided detection of pulmonary embolism. *Scientific Data*, 5(1), 180180. <https://doi.org/10.1038/sdata.2018.180>
- [3] Morales-Blanhir, J. E., Salas-Pacheco, J. L., Rosas-Romero, M. de J., & Valle-Murillo, M. Á. (2011). Diagnóstico de tromboembolia pulmonar. *Archivos de cardiología de Mexico*, 81(2), 126–136. Recuperado de: https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1405-99402011000200009
- [4] (S/f). Rev-esp-patol-torac.com. Recuperado de: <https://www.rev-esp-patol-torac.com/files/publicaciones/Revistas/2000/NS2000.12.1.A03.pdf>
- [5] (S/f). Uam.es. Recuperado de: https://repositorio.uam.es/bitstream/handle/10486/679012/parra_gordo_mariluz.pdf?sequence=1
- [6] Şentürk, A., Argüder, E., Babaoğlu, E., Hezer, H., & Hasanoğlu, H. C. (2013). Diagnóstico por la imagen del tromboembolismo pulmonar mediante ecografía endobronquial. *Archivos de Bronconeumología*, 49(6), 268–271. Recuperado de: <https://doi.org/10.1016/j.arbres.2012.08.006>
- [7] Recuperado de: <http://alojamientos.us.es/gtocom/pid/tema4.pdf>
- [8] Alfaro, A & Sipirán, I. Diseño de un Algoritmo de Segmentación de Imágenes aplicando el Funcional de Mumford-Shah para mejorar el

desempeño de los Algoritmos Clásicos de Segmentación. Recuperado de <http://www.ivan-sipiran.com/papers/segvar.pdf>

[9] Phy, J. (2020). Medical image processing using Python and Open CV. Recuperado de: <https://iopscience.iop.org/article/10.1088/1742-6596/1524/1/012003/pdf>

[10] Weerakkody, Y., & D'Souza, D. (2008). Pulmonary embolism. En *Radiopaedia.org*. Radiopaedia.org. Recuperado de: <https://radiopaedia.org/articles/pulmonary-embolism>

[11] Osio, J. R., & Walter, A. (s/f). *Desarrollo de Algoritmos de Procesamiento de Imágenes Basados en "Operadores de Ventana" sobre una FPGA*. Edu.ar. Recuperado de: https://www.ing.unlp.edu.ar/sitio/investigacion/archivos/jornadas2011/i_e13.pdf

[12] Calvillo Batllés, P. (2017). Algoritmo para el diagnóstico y el seguimiento de la tromboembolia pulmonar aguda. *Radiología*, 59(1), 75–87. Recuperado de: <https://doi.org/10.1016/j.rx.2016.10.001>.

[13] Lozano, L., & Fernando, D. (2021). *Metodología de segmentación de instancias multiplano para la detección de tromboembolismo pulmonar*. Universidad de los Andes. Recuperado de: <https://repositorio.uniandes.edu.co/handle/1992/55775>

[14] Zhang, C., Sun, M., Wei, Y., Zhang, H., Xie, S., & Liu, T. (2019). Automatic segmentation of arterial tree from 3D computed tomographic pulmonary angiography (CTPA) scans. *Computer Assisted Surgery (Abingdon, England)*, 24(sup2), 79–86. Recuperado de: <https://doi.org/10.1080/24699322.2019.1649077>

[15] Nunez-Iglesias, J.,; R Stephen M. Plaza, Chakraborty, A & Katz, W. (2014). Graph-based active learning of agglomeration (GALA): a Python library to segment 2D and 3D neuroimages. Recuperado de <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3983515/>

[16] <http://alojamientos.us.es/gtocoma/pid/introduccion.html>
Procesamiento de imágenes digitales.

[17]

http://bibliotecadigital.ilce.edu.mx/sites/ciencia/volumen2/ciencia3/084/htm/sec_9.htm Procesamiento de imágenes digitales.

[18]

https://es.wikipedia.org/wiki/Procesamiento_digital_de_im%C3%A1genes Procesamiento de imágenes digitales.

[19] <http://biblioteca.utb.edu.co/notas/tesis/0040434.pdf> Técnicas de procesamiento de imágenes bidimensionales

[20]

https://www.researchgate.net/publication/330183469_Segmentacion_de_imagenes Información sobre segmentación.

[21] Reynolds, D. (n.d.). *Gaussian Mixture Models*. Iisc.Ac.In. Retrieved January 28, 2023, from http://leap.ee.iisc.ac.in/sriram/teaching/MLSP_16/refs/GMM_Tutorial_Reynolds.pdf

[22] <https://ietresearch.onlinelibrary.wiley.com/doi/full/10.1049/iet-gtd.2019.1349>

[23] https://energia.gob.es/es-ES/Participacion/Documents/propuesta-mercado-hibrido-mibel/PO_3_1_MI%20Continuo_CC_mod-A-B.pdf

[24] Mask_RCNN: Mask R-CNN for object detection and instance segmentation on Keras and TensorFlow. (n.d.). Recuperado de: https://github.com/matterport/Mask_RCNN

[25] "How to Hounsfield: Blood or Ascites?", Kings County EM, 2020. Available: <http://blog.clinicalmonster.com/2020/06/02/how-to-hounsfield-in-emergency-medicine/>.

[26] "Detection Evaluation", COCO - Common Objects in Context, 2021. Recuperado de: <https://cocodataset.org/#detection-eval>.

[27] R. Grosse, N. Srivastava. CSC321. Class Lecture, Topic: "Mixture models." Department of Computer Science, University of Toronto, 2015.

Recuperado de:
https://www.cs.toronto.edu/~rgrosse/csc321/mixture_models.pdf

[28] K. Long, P_mask_RCNN for pulmonary embolism (PE) detection and segmentation. [Online]. Recuperado de: https://github.com/longkun-uestc/P_Mask_RCNN

[29] W. Abdulla, Mask r-cnn for object detection and instance segmentation on keras and tensorflow. Recuperado de: https://github.com/matterport/Mask_RCNN.

[30] M. Masoudi and M. Saadatmand-Tarzjan, "FUMPE". figshare, 22-May-2018. Recuperado de: <https://figshare.com/collections/FUMPE/4107803/1>.

[31] T. DenOtter and J. Schubert, "Hounsfield Unit", StatPearls [Internet]. Treasure Island (FL): StatPearls Publishing, 2021. Recuperado de: <https://www.ncbi.nlm.nih.gov/books/NBK547721/>.

[32] A. Virdee, "Understanding DICOMs", Towards Data Science, 2021. Recuperado de: <https://towardsdatascience.com/understanding-dicom-835cd2e57d0b>.

[33] <https://www.youtube.com/watch?v=Xnc5JQxWVys> Vídeo sobre introducción al procesamiento de imagen digital.

[34] <https://www.youtube.com/watch?v=N8F5NVI-ksE> Vídeo sobre uso de imágenes en Python.

[35] <https://www.youtube.com/watch?v=NItHNRc3awY> Tutorial 02 sobre qué es el procesamiento de imágenes digitales.

[36] <https://www.youtube.com/watch?v=Q5yVpymvjxU> Tutorial 22 sobre como cargar imágenes en Python.

APÉNDICE: Carga de trabajo de los componentes

FECHA	INICIO	FIN	PAUSA	TPO. TOTAL	ACTIVIDAD
9/10/2022	16:30	20:00	No	3 hora y media	Elección del tema del Tdt
12/10/2022	15:30	17:30	No	2 horas	Lectura sobre artículos relacionados con el Tdt
2/10/2022	16:00	20:00	1 hora	3 horas	Realización del AEC2
13/11/2022	9:00	12:00	15 min	3 horas	Planteamiento y comienzo del Tdt
18/11/2022	12:00	13:00	No	1 hora	Planteamiento y comienzo del Tdt
21/11/2022	16:30	20:30	No	4 horas	Realización del AEC4
14/12/2022	11:00	15:00	No	4 horas	Introducción y contexto biomédico
14/12/2022	16:00	20:00	1 hora	3 horas	Marco teórico
17/12/2022	17:30	19:30	20 min	1 hora y 40 min	Algoritmia y marco teórico
18/12/2022	19:00	21:00	No	2 horas	Secciones y algoritmia
21/12/2022	16:00	20:00	No	4 horas	Marco teórico
26/12/2022	8:30	12:00	25 min	3 horas	Secciones y algoritmia
26/12/2022	16:30	22:30	1 hora	5 horas	Secciones y algoritmia
27/12/2022	10:00	14:15	No	4 horas y 15 min	Experimentación
28/12/2022	11:00	14:15	No	3 horas y 15 min	Experimentación
2/01/12	9:30	14:00	No	4 horas y media	Experimentación
8/01/2023	9:15	14:15	No	5 horas	Secciones y experimentación
8/01/2023	16:15	0:45	1 hora	7 horas y media	Marco teórico del problema y algoritmia
11/01/2023	16:00	20:45	35 min	4 horas y media	Algoritmia y experimentación
13/01/2023	16:00	21:00	No	5 horas	Secciones y conclusiones
14/01/2023	17:00	19:00	No	2 horas	Revisión del Tdt
15/01/2023	16:30	1:30	2 horas y media	7 horas y media	Experimentación y conclusiones
16/01/2023	9:00	13:30	30 min	4 horas	Realización de la presentación
17/01/2023	18:00	22:00	No	4 horas	Realización del video
20/01/2023	10:00	14:00	No	4 horas	Revisión de todo

